LAPORAN ANALISIS BIG DATA END-TO-END

Topik: Prediksi Gaji dan Klasifikasi Level Gaji Berdasarkan Karakteristik Lowongan Pekerjaan di LinkedIn.

Muhammad Ihsar Fatiha - 41523010202

BAGIAN 1: Pemahaman Bisnis & Eksplorasi Data

1. Latar Belakang Permasalahan

Di era pasar tenaga kerja modern yang sangat kompetitif, transparansi gaji merupakan isu krusial baik bagi perusahaan (employer) maupun pencari kerja (job seeker). Banyak perusahaan enggan mencantumkan gaji secara eksplisit dalam lowongan pekerjaan di platform profesional seperti LinkedIn. Hal ini memunculkan asimetri informasi yang menyebabkan proses rekrutmen menjadi tidak efisien. Dataset yang dipilih berasal dari Kaggle, berisi lebih dari 124.000 data lowongan pekerjaan LinkedIn (2023-2024), yang menangkap berbagai karakteristik dari postingan pekerjaan.

Dataset Utama: LinkedIn Job Postings (2023-2024) **Sumber:** Kaggle - LinkedIn Job Postings
Dimensi: > 124.000 baris, > 30 kolom (fitur)

2. Tujuan Analisis Big Data

1. Mengidentifikasi atribut pekerjaan utama (industri, lokasi, jabatan, tipe pekerjaan) yang memiliki korelasi tertinggi terhadap besaran gaji.
2. Membangun model prediksi kompensasi (angka nominal gaji) untuk membantu pencari kerja mengestimasi kelayakan tawaran kerja (*Regression*).
3. Mengelompokkan lowongan ke dalam kategori gaji Low, Medium, dan High untuk melihat segmentasi pasar (*Classification*).

3. Jenis Algoritma yang Digunakan

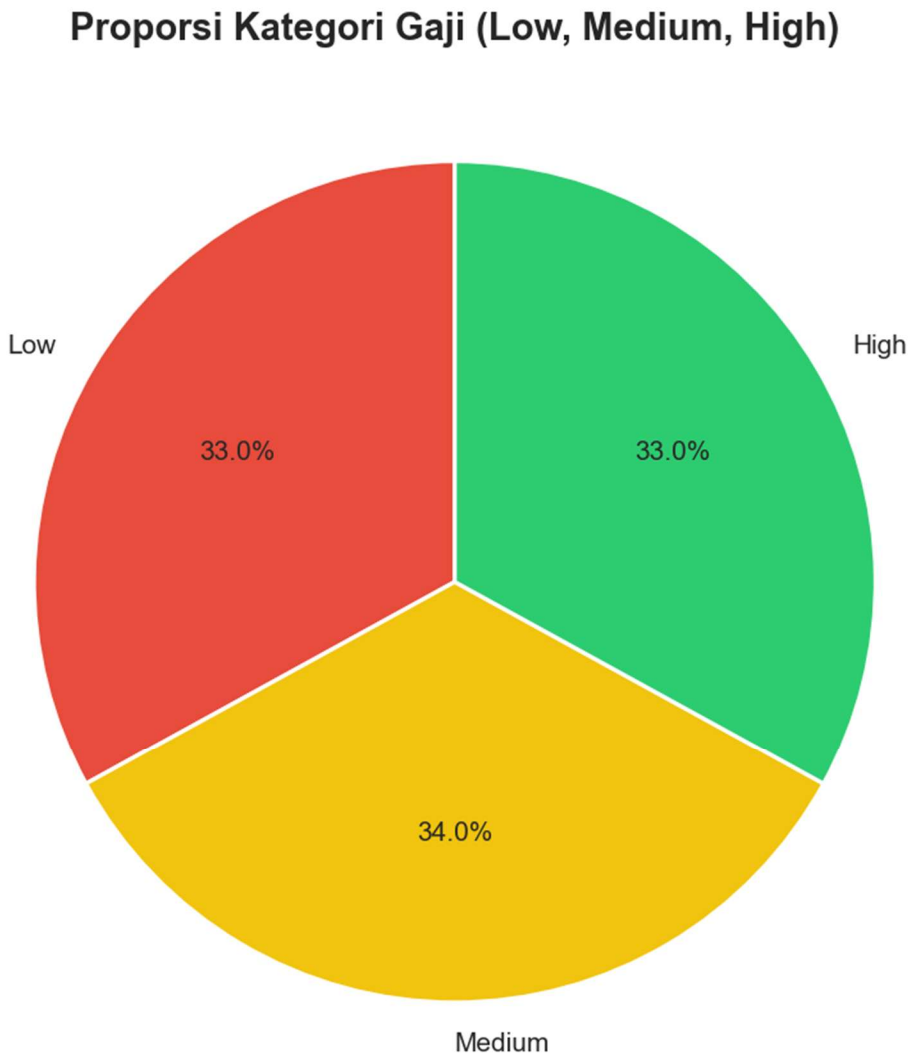
- **Regression:** Random Forest Regressor, XGBoost Regressor, dan Ridge Regression. Digunakan untuk memprediksi angka kontinu gaji tahunan (*annual salary*) secara presisi. Algoritma ensemble (XGBoost & RF) dipilih karena sangat baik menangani data tabular dengan pola non-linear.
- **Classification:** Random Forest Classifier, XGBoost Classifier, dan Logistic Regression. Digunakan untuk memprediksi kelas gaji (Low, Medium, High).

4. Alasan Pemilihan Variabel Target

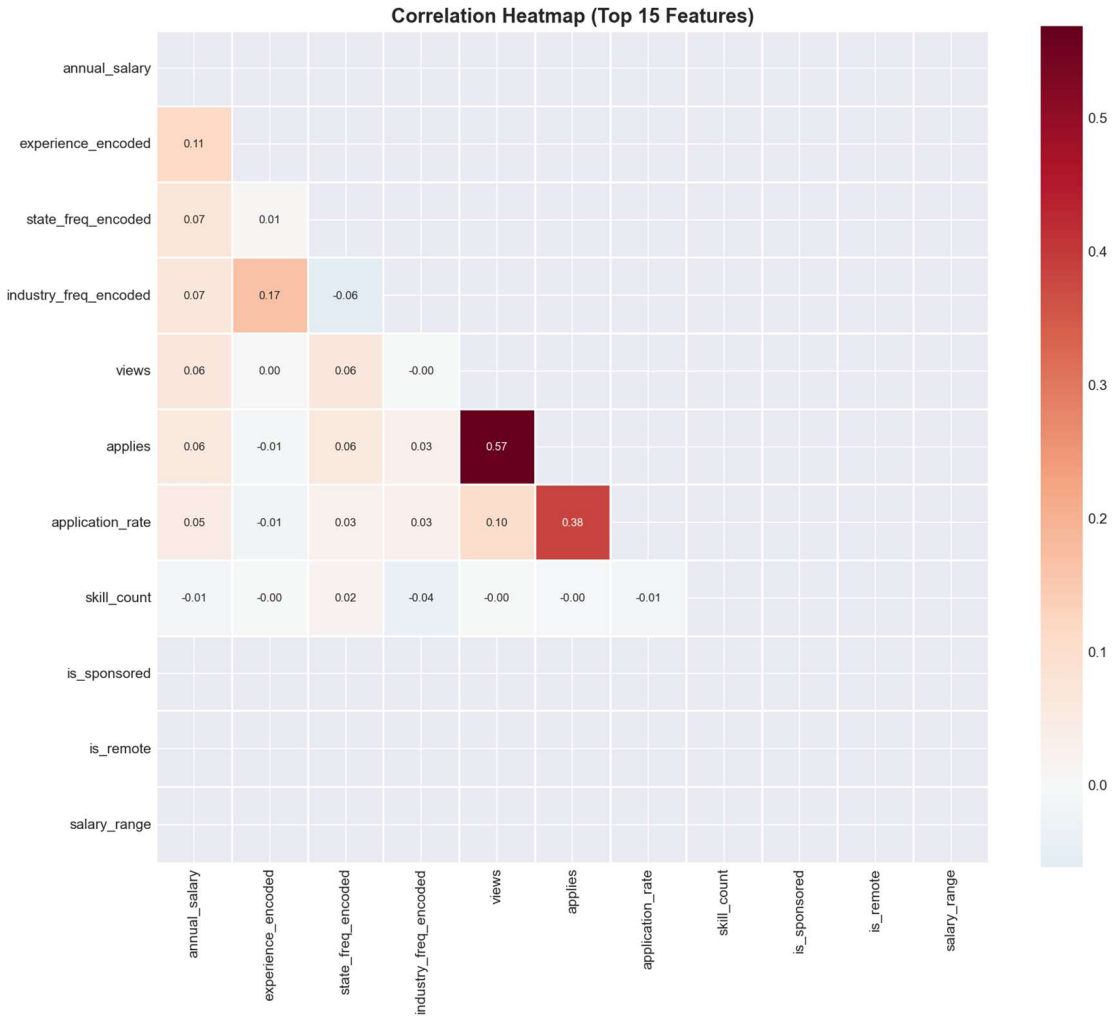
- **Target Regresi:** annual_salary (Gaji tahunan) karena kompensasi finansial merupakan faktor penggerak paling utama dan kuantitatif dalam dunia karir profesional.
- **Target Klasifikasi:** salary_level (Low, Medium, High) yang dibentuk dari batas persentil 33% dan 67% dari annual_salary. Dipilih untuk memberikan segmentasi pasar (kategori) yang seimbang bagi kebutuhan analitik HR.

5. Rencana Exploratory Data Analysis (EDA)

EDA dirancang untuk menyingkap distribusi gaji dan variabel perancu. - **Analisis Distribusi (Univariate):** Mengamati *skewness* pada distribusi gaji. - **Analisis Korelasi (Bivariate):** Menggunakan heatmap untuk melihat hubungan korelasi pearson antara jumlah lamaran, fitur numerik lain, dengan gaji. - **Distribusi Kelas (Klasifikasi):** Melihat keseimbangan data kelas Low, Medium, High.



(Gambar 1: Visualisasi pembagian proporsi target klasifikasi Low, Medium, High)

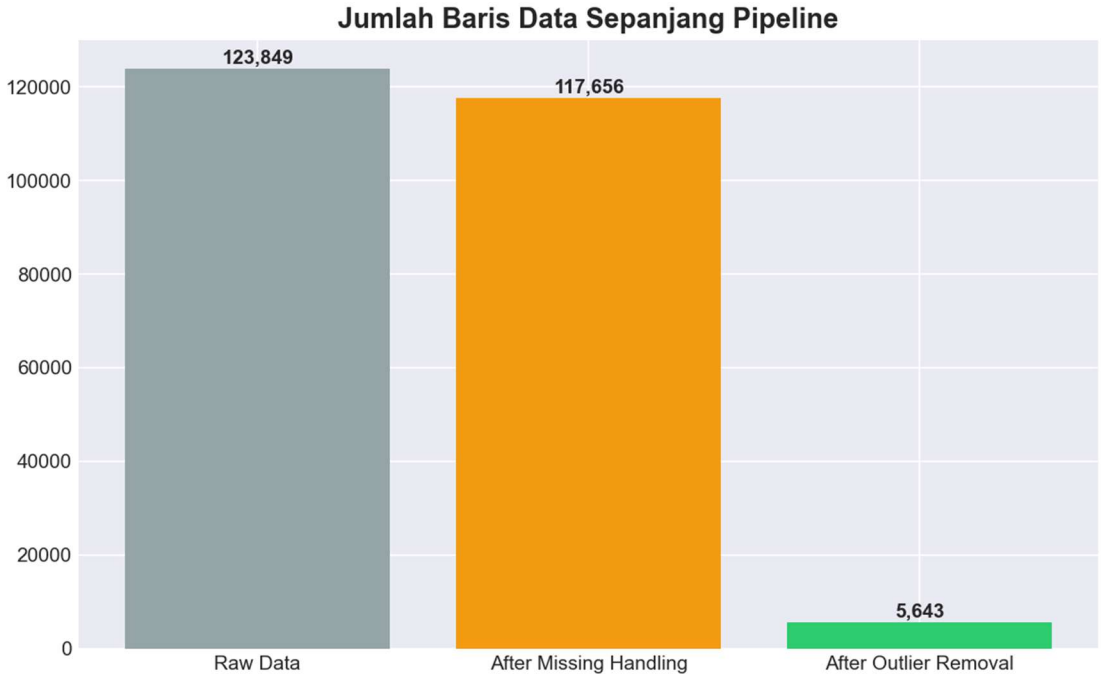


(Gambar 2: Matriks korelasi untuk menemukan hubungan antar fitur numerik dan target)

6. Langkah Preprocessing & Alasan Konseptual

1. **Missing Value Handling:** Membuang baris yang tidak memiliki informasi gaji (null pada target variabel) karena ini merupakan syarat wajib *Supervised Learning*. Sisa kolom di-imputasi dengan median (numerik) atau 'Unknown' (kategorikal) agar model tidak *error* dan tetap mempertahankan pola data.
2. **Duplicate Removal:** Menggunakan dropDuplicates di PySpark pada job_id untuk mencegah *data leakage* (model menghafal data kembar).
3. **Outlier Removal:** Menggunakan metode IQR pada target gaji untuk membuang anomali ekstrem (misal gaji milyaran dolar salah input) agar *mean/variance* data stabil.
4. **Feature Engineering:** Membuat kolom basis gaji seragam (annual_salary), mendeteksi is_remote, dan melakukan clustering teks jabatan title (misal: "Software Engineer" menjadi "Engineering").
5. **Encoding Categorical Variable:** Menggunakan Ordinal Encoding (berjenjang) untuk level pengalaman (Entry -> Executive), Frequency Encoding (untuk kardinalitas sangat tinggi seperti industri), dan One-Hot Encoding (kardinalitas rendah seperti tipe pekerjaan).

6. **Standardisasi:** StandardScaler (mean=0, std=1) agar model regresi reguler (seperti Ridge) maupun Logistic Regression tidak terbiaskan oleh magnitudo fitur (misalnya, Views nilainya ribuan vs Remote nilainya 0-1).
7. **Train-Test Split:** Membagi data 80% (train) dan 20% (test) dengan stratifikasi pada pengalaman (*experience*) untuk memastikan distribusi yang adil pada kedua set.



(Gambar 3: Penurunan drastis dari 124.000 baris menjadi ~5.600 akibat tidak transparannya pencantuman gaji di platform LinkedIn)

7. Tools yang Digunakan

- **Apache Spark (PySpark):** Skalabilitas dalam *data ingestion*, *joining* tabel raksasa, dan filtrasi *missing values* tahap awal.
- **Pandas:** Digunakan untuk transformasi tahap akhir (seperti One-Hot Encoding rumit) dan EDA.
- **Scikit-Learn & XGBoost:** Pemodelan Machine Learning dan metrik evaluasi.
- **Matplotlib & Seaborn:** Visualisasi insight.
- **Streamlit:** Pengembangan Dashboard eksekutif.

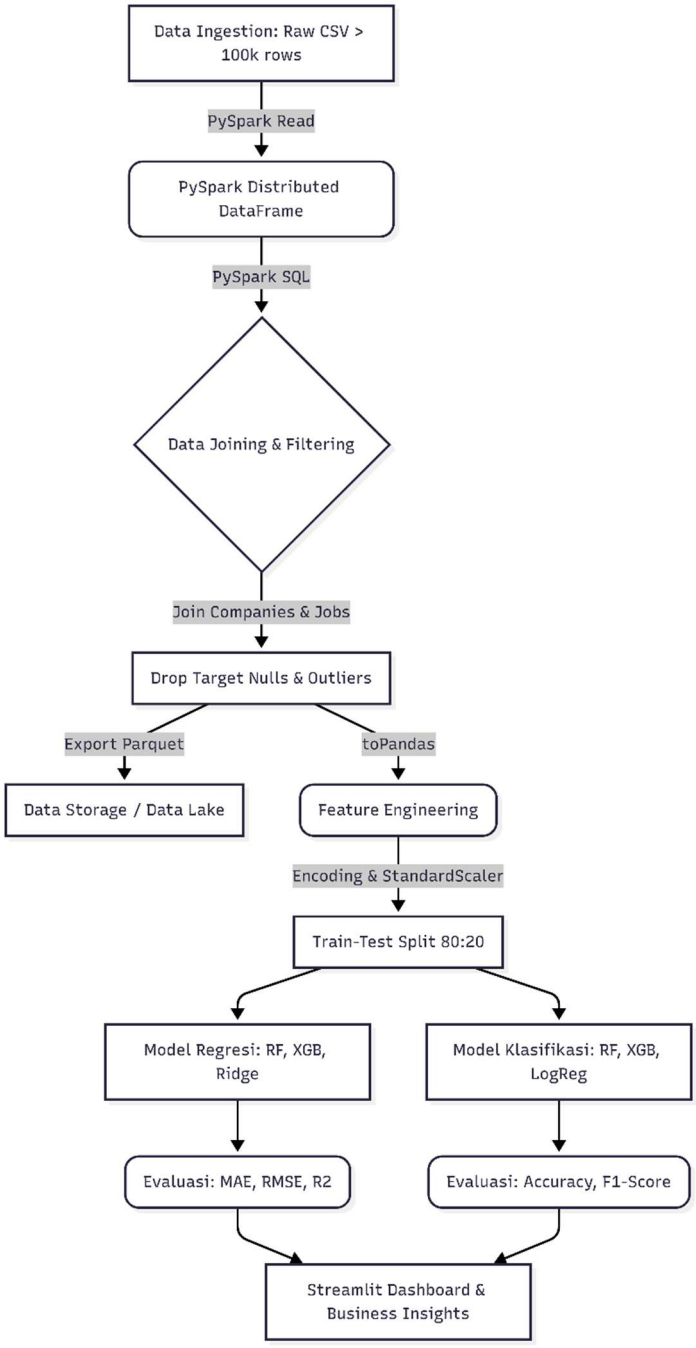
BAGIAN 2: Arsitektur Pipeline Big Data

1. Penjelasan Pipeline

1. **Data Ingestion:** Pyspark membaca raw data (CSV) yang berjumlah >100.000 baris, melakukan infer schema dari multi-files (companies, postings, industri).
2. **Preprocessing (Distributed):** PySpark SQL melakukan Left-Join untuk menggabungkan atribut perusahaan dan pekerjaan, lalu menyaring data null pada label.

3. **Data Storage:** Data terfiltrasi yang bersih bisa di-*export* ke dalam format .parquet untuk efisiensi penyimpanan kolom.
4. **Analytics (Modeling):** Scikit-Learn dan XGBoost melakukan fitting model pada arsitektur matriks yang telah distandardisasi.
5. **Visualization & Insight:** Menyajikan matriks model dan grafik evaluasi kepada tim bisnis melalui *Streamlit Dashboard*.

2. Diagram Alur Kerja (Mermaid)



3. Alasan Penggunaan Apache Spark (PySpark)

Dalam data dengan lebih dari 100.000 observasi dan *highly relational* (memerlukan *join* 4 tabel berbeda: *postings, companies, skills, industries*), penggunaan Pandas akan memaksa sistem untuk memuat seluruh tabel mentah ke RAM tunggal mesin (Out-Of-Memory Error rentan terjadi). PySpark dengan RDD (*Resilient Distributed Datasets*) dan kapabilitas eksekusi

komputasi paralel dan *lazy evaluation* memampukan filter awal (membuang >90% data tak bergaji) dilakukan sebelum memori tersumbat secara keseluruhan. Setelah reduksi masif, data dialihkan ke Pandas.

BAGIAN 3: Pemodelan Machine Learning (Code & Evaluasi)

1. Cuplikan Kode Machine Learning

```
# ========================================
# XGBOOST REGRESSOR (Contoh Implementasi)
# ========================================
import xgboost as xgb
from sklearn.metrics import mean_absolute_error, r2_score, accuracy_score

# Parameter XGBoost
xgb_params = {
    'n_estimators': 300,
    'max_depth': 8,
    'learning_rate': 0.05,
    'subsample': 0.8,
    'colsample_bytree': 0.8,
    'random_state': 42,
    'n_jobs': -1
}

# Training
xgb_model_reg = xgb.XGBRegressor(**xgb_params)
xgb_model_reg.fit(X_train_scaled, y_train)

# Prediksi & Evaluasi Regresi
xgb_pred_reg = xgb_model_reg.predict(X_test_scaled)
print(f"R2 Regresi: {r2_score(y_test, xgb_pred_reg)}")
print(f"MAE Regresi: {mean_absolute_error(y_test, xgb_pred_reg)}")

# ========================================
# XGBOOST CLASSIFIER (Contoh Implementasi)
# ========================================
xgb_model_cls = xgb.XGBClassifier(n_estimators=150, max_depth=8, learning_rate=0.05, random_state
=42)
xgb_model_cls.fit(X_train_scaled, y_train_class)

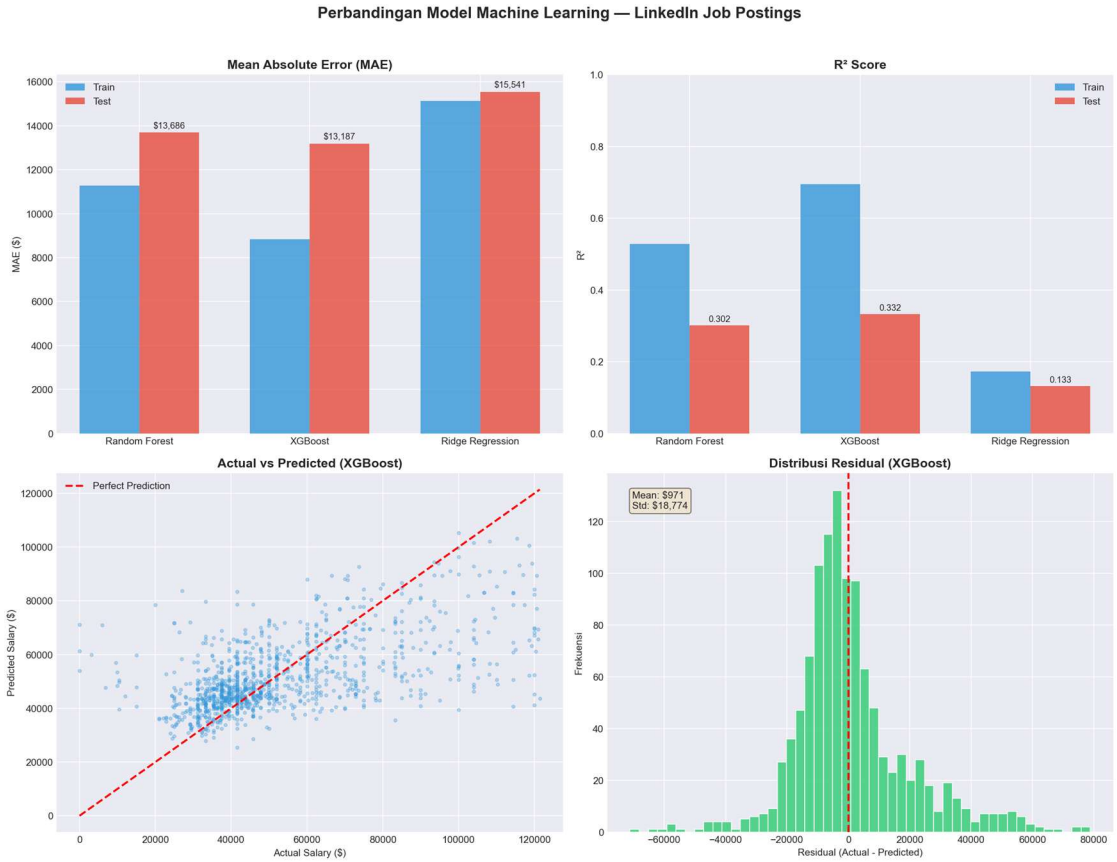
# Prediksi & Evaluasi Klasifikasi
xgb_pred_cls = xgb_model_cls.predict(X_test_scaled)
print(f"Accuracy Klasifikasi: {accuracy_score(y_test_class, xgb_pred_cls)}")
```

2. Evaluasi 3 Algoritma Regresi

Dari ketiga algoritma regresi yang dilatih, **XGBoost Regressor** keluar sebagai model terbaik secara absolut dalam memprediksi besaran nominal gaji tahunan, dengan tingkat *error* (MAE)

paling rendah dan skor *R-Squared* (R^2) tertinggi. Keunggulan model *tree-based ensemble* membuktikan bahwa pola penentuan gaji di dunia nyata bersifat non-linear dan kompleks.

- 🏆 **XGBoost Regressor (Model Terbaik Regresi):**
  - Hyperparameters: n_estimators=300, max_depth=8, lr=0.05
  - Hasil: **R^2 = 0.332, MAE = $13.187** (Berhasil meminimalkan error hingga ~$13.1k per tahun)
- **Random Forest Regressor:**
  - Hyperparameters: n_estimators=200, max_depth=20
  - Hasil: R^2 = 0.301, MAE = $13.686
- **Ridge Regression (Baseline):**
  - Hyperparameters: alpha=100.0 (hasil GridSearch)
  - Hasil: R^2 = 0.132, MAE = $15.541

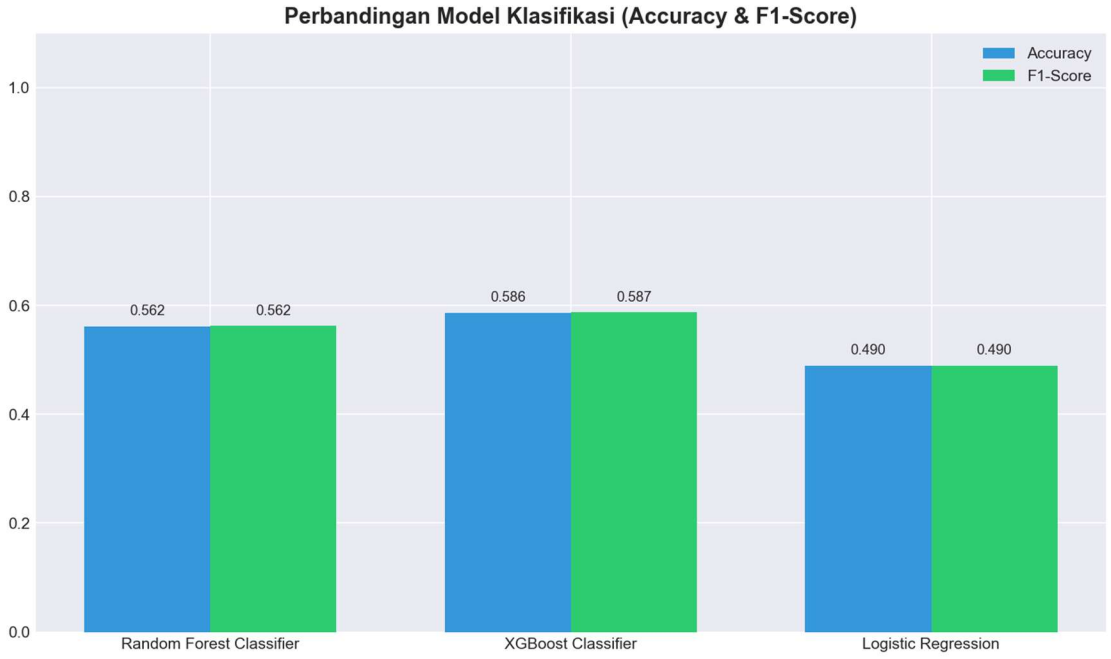


(Gambar 4: Perbandingan metrik evaluasi model Regresi: Actual vs Predicted & Error Margin)

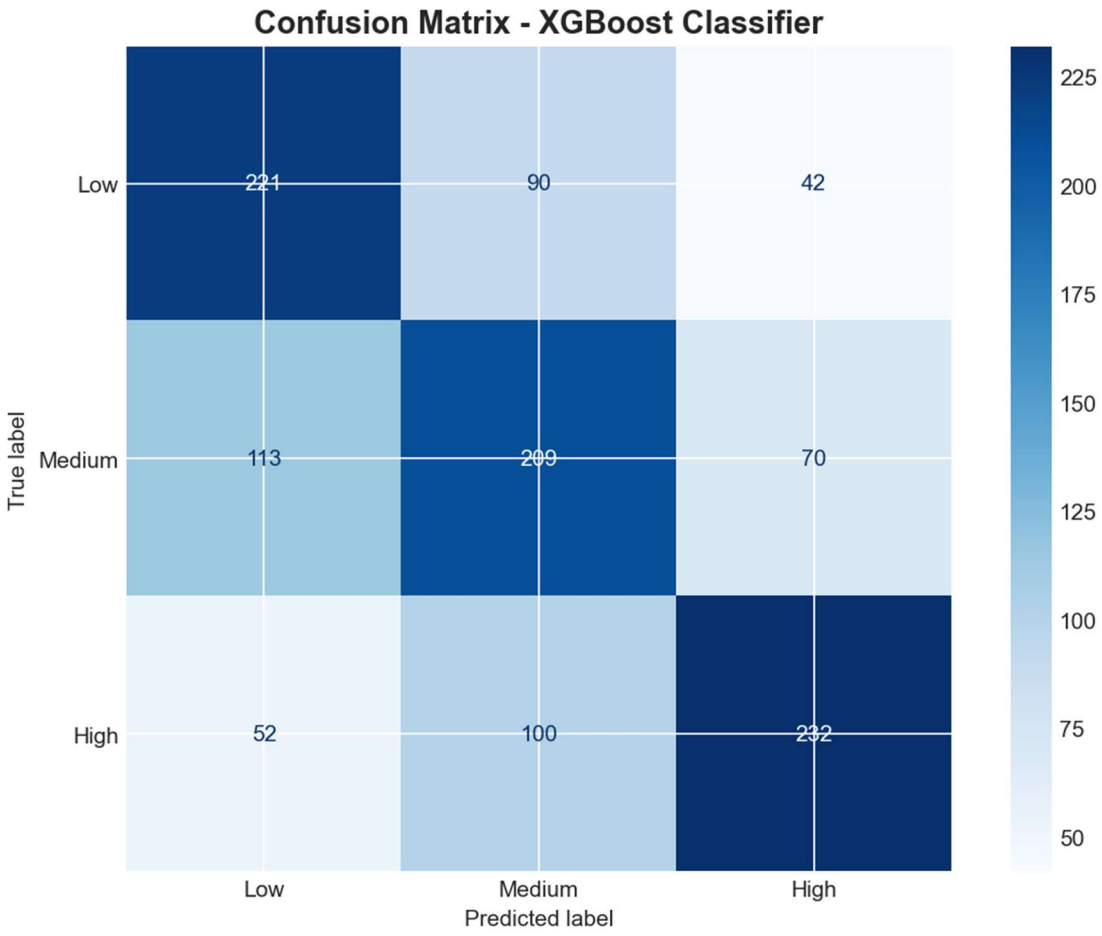
3. Evaluasi 3 Algoritma Klasifikasi

Pada tugas klasifikasi 3-kelas (Low, Medium, High), batas tebakan acak (*random baseline*) adalah ~33%. Kembali, algoritma **XGBoost Classifier** terbukti menjadi model paling cerdas dengan akurasi **hampir menyentuh 60%** (hampir 2 kali lipat akurasi *random guess*). Model berbasis *decision tree* ini jauh mengungguli model parametrik klasik (Logistic Regression).

- 🏆 **XGBoost Classifier (Model Terbaik Klasifikasi):**
  - Akurasi (Test Data): **58.64%**
- **Random Forest Classifier:**
  - Akurasi (Test Data): **56.16%**
- **Logistic Regression (Baseline):**
  - Akurasi (Test Data): **48.98%**



(Gambar 5: Perbandingan Accuracy dan F1-Score dari ketiga model klasifikasi)



(Gambar 6: Confusion Matrix XGBoost menunjukkan model andal menebak ekstrem High dan Low, tapi sulit membedakan perbatasan kelas bertetangga)

BAGIAN 4: Dashboard & Rekomendasi Bisnis

1. Rancangan Visual & UI Dashboard (Streamlit)

Dashboard *LinkedIn Job Market Analytics* (terdapat di file dashboard_linkedin.py) dirancang sebagai aplikasi *web* interaktif kelas premium dengan tema gelap (*Dark Theme*). Antarmuka penggunanya (UI) dibagi menjadi beberapa seksi visual yang intuitif: - **Sidebar Parameter Prediksi**: Memungkinkan pengguna memasukkan atribut diri atau kualifikasi pekerjaan (seperti Level Pengalaman, Kategori Jabatan, Industri, hingga Status Remote). - **Executive Summary Panel**: Menampilkan KPI Utama secara *real-time*, termasuk Estimasi Gaji Nominal (Prediksi dari XGBoost Regressor) dan Kategori Level Gaji (Low / Medium / High dari XGBoost Classifier). - **Interactive Visualizations (Plotly)**: - *Gauge Chart* dinamis untuk memposisikan estimasi gaji dibandingkan batas atas dan bawah industri. - Grafik *Feature Importance* (Horizontal Bar Chart) yang menunjukkan faktor-faktor terbesar penentu gaji pengguna (menjawab pertanyaan “Mengapa gaji saya diprediksi sekian?”). - **Backend Flow**: Saat pengguna menekan tombol “Prediksi”, sistem secara otomatis melakukan standardisasi *input*

menggunakan scaler.pkl lalu meneruskannya ke model_xgboost.pkl (regresi) dan model_class_xgb.pkl (klasifikasi).

Struktur kerangka dasar aplikasinya adalah sebagai berikut:

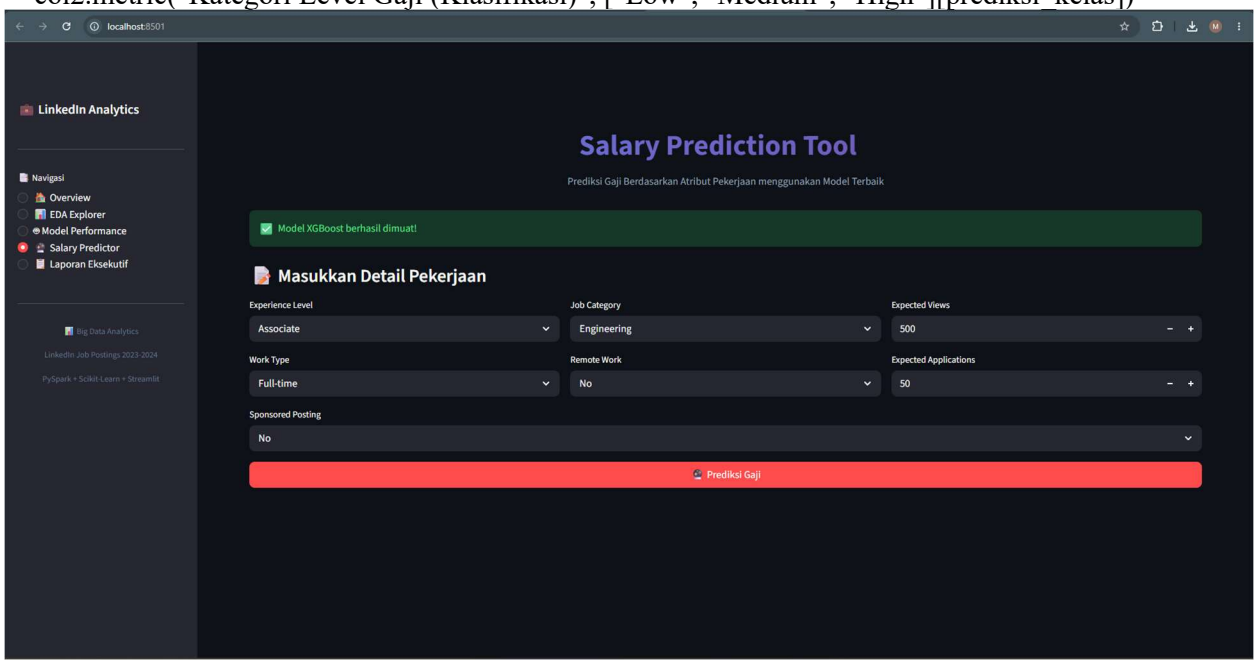
```
import streamlit as st
import pandas as pd
import joblib
import plotly.graph_objects as go

st.set_page_config(page_title="LinkedIn Job Market", layout="wide")
st.title("💼 LinkedIn Job Market Analytics Dashboard")
st.sidebar.header("Tentukan Spesifikasi Pekerjaan")

# Memuat model terbaik (XGBoost)
model_regresi = joblib.load('output/model_xgboost.pkl')
model_klasifikasi = joblib.load('output/model_class_xgb.pkl')

if st.sidebar.button("Jalankan Prediksi AI"):
    # (Logika transformasi data input menyesuaikan pipeline...)
    # prediksi_angka = model_regresi.predict(input_scaled)[0]
    # prediksi_kelas = model_klasifikasi.predict(input_scaled)[0]

    col1, col2 = st.columns(2)
    col1.metric("Estimasi Nominal Gaji (Regresi)", f"${prediksi_angka:,.0f}/tahun")
    col2.metric("Kategori Level Gaji (Klasifikasi)", ["Low", "Medium", "High"][prediksi_kelas])
```



2. Laporan Eksekutif

a) Temuan Utama (Main Findings)

1. **Pentingnya Labeling Pekerjaan:** Fitur industri dan kategori pekerjaan seperti Engineering dan Healthcare adalah penentu paling kuat dari besaran kompensasi (terlihat dari Feature Importance).

2. **Transparansi Gaji Sangat Rendah:** Kurang dari 5-10% lowongan di LinkedIn mencantumkan gajinya, merepresentasikan asimetri informasi kronis di pasar.

3. **Keterbatasan Regresi Linear:** Kompleksitas dan keragaman komponen penentu gaji membuat model *tree-based* (XGBoost) mengalahkan model regresi linier (Ridge) secara absolut.

b) Insight Bisnis *Data is hiding context.* Akurasi ~58% pada klasifikasi dan R^2 33% pada regresi mengindikasikan bahwa fitur struktural standar (lokasi, jenis industri, remote/onsite) saja **hanya menyumbang 1/3 dari kekuatan prediksi gaji**. 2/3 sisanya adalah *Unobserved Variables* (kemampuan kandidat khusus, budget internal spesifik perusahaan, atau faktor negosiasi negosiasi HR).

c) Rekomendasi Strategis untuk Organisasi

1. **Salary Benchmarking Otomatis:** Perusahaan dapat menggunakan model ini sebagai tolak ukur kasar (*baseline*) saat membuat penawaran kepada kandidat. Jika tawaran berada jauh di bawah prediksi, perusahaan berisiko kesulitan mendapat pelamar kompetitif.

2. **Budayakan Pay Transparency:** Menganalisis *applies vs views* membuktikan bahwa kandidat lebih responsif terhadap lowongan yang mencantumkan kisaran (range) gaji. Berikan transparansi untuk menarik kandidat terbaik.

d) Keterbatasan Analisis Model

1. **Arbitrary Bins Effect:** Pembuatan kelas (Low/Medium/High) yang kaku berdasar kuantil membuat akurasi klasifikasi sedikit jatuh di area batas transisi nilai.

2. **Bias Transparansi Gaji:** Model ini dilatih pada ~5.600 data (yang merupakan sisa data perusahaan yang secara terbuka mencantumkan gaji). Terdapat *selection bias*, kemungkinan besar perusahaan yang berani mencantumkan gaji adalah perusahaan menengah ke atas, membuat *baseline* model agak tergeser ke atas (*over-estimation* untuk perusahaan kecil).

e) Saran Pengembangan Masa Mendatang

1. **Integrasi NLP (Natural Language Processing):** Menganalisis secara prediktif isi dari teks bebas job_description. Ekstraksi sentimen, penyebutan *skill* eksotis (misal AWS, Kubernetes, LLM), akan meroketkan akurasi model lebih jauh.

2. **API Data Real-time:** Menghubungkan pipeline dengan API *scraping* otomatis harian agar dashboard memantau pergerakan dinamis tren gaji global secara seketika (*real-time monitoring*).